ΕΛΛΗΝΙΚΗ ΔΗΜΟΚΡΑΤΙΑ
Εθνικόν και Καποδιστριακόν Πανεπιστήμιον Αθηνών
ΙΔΡΥΘΕΝ ΤΟ 1837

ΤΜΗΜΑ ΜΑΘΗΜΑΤΙΚΩΝ

Στατιστική Ανάλυση Επαγγελμάτων στον Καναδά του 1971

Μάθημα: Γραμμικά μοντέλα

Διδάσκουσα: Λουκία Μελιγκοτσίδου

Ομαδική εργασία των:

Γεώργιος Λαμπρόπουλος

Ιάσων Λισγάρας

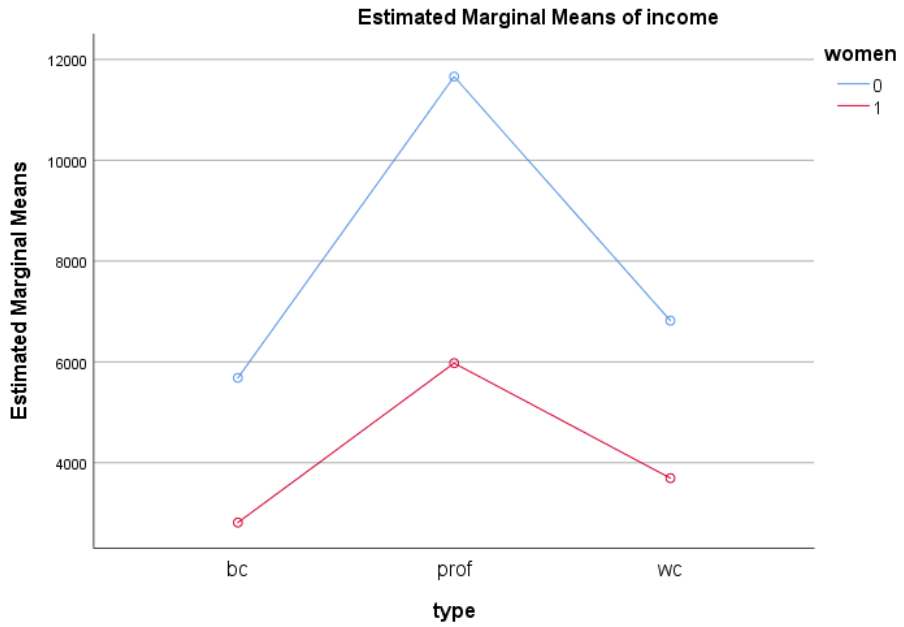
Αθήνα

Ιούνιος 2023

Στατιστική Ανάλυση Επαγγελμάτων στον Καναδά του 1971

Σε αυτή την αναφορά, μελετάμε εις βάθος τον εργασιακό χώρο του Καναδά της δεκαετίας του 1970, εφαρμόζοντας στην πορεία στατιστική ανάλυση σε μία ευρεία γκάμα στοιχείων και δεδομένων που παρατηρήθηκαν για 102 επαγγέλματα της εποχής. Πιο συγκεκριμένα, μελετάμε σχέσεις μεταξύ ορισμένων παραγόντων που συνδέονται με τα επαγγέλματα, όπως η εκπαίδευση, το εισόδημα, το φύλο, το κύρος και ο τύπος του επαγγέλματος. Αυτό μας οδηγεί σε μία σειρά από συμπεράσματα που μας βοηθούν να πάρουμε μία ιδέα για την αγορά εργασίας της εποχής. Αρχικά βλέπουμε πως το κύρος ενός επαγγέλματος συνδέεται άμεσα με το εισόδημα και τα μέσα έτη εκπαίδευσης των αντίστοιχων επαγγελματιών. Επιπλέον, παρατηρούμε πως τα επαγγέλματα στα οποία επικρατούν οι γυναίκες πληρώνουν εμφανώς λιγότερα σε σχέση με τα υπόλοιπα. Στην ανάλυση μας βλέπουμε πώς ο μισθός των παραπάνω είναι μισός σε σχέση με τον μέσο όρο. Τέλος, μετά από μελέτη συμπεραίνουμε ότι ενώ τα χειρωνακτικά επαγγέλματα καθώς και οι επαγγελματίες γραφείου πληρώνονται αρκετά κοντά στον συνολικό μέσο όρο, οι επαγγελματίες, διοικητικοί και τεχνικοί λαμβάνουν σχεδόν τις διπλάσιες αποδοχές.

Τα παραπάνω φαίνονται συνοπτικά και στο ακόλουθο διάγραμμα:



1. Περιγραφικά Στατιστικά Μέτρα

Α. Εκπαίδευση

Παρατηρούμε πως κατά μέσο όρο η εκπαίδευση των Καναδών την δεκαετία του 70 έγκειται σε αρκετά υψηλά επίπεδα, έχοντας μέσο όρο περίπου 10 έτη και μικρή διασπορά. Επιπλέον, αφού η λοξότητα είναι θετική καταλαβαίνουμε πως περισσότεροι βρίσκονται κάτω από των μέσο όρο ,παρά πάνω. Παράλληλα εφόσον η κύρτωση είναι αρνητική συμπεραίνουμε πως οι ‘’ουρές’’ είναι λεπτές, δηλαδή οι ακραίες τιμές (χαμηλό ή υψηλό επίπεδο εκπαίδευσης) σπανίζουν, το οποίο περιμέναμε.

Β. Εισόδημα

Όσον αφορά το εισόδημα, βλέπουμε πως το μέσο εισόδημα είναι της τάξης των 6 χιλιάδων δολαρίων ,με μεγάλη όμως διασπορά. Θετική κύρτωση συνεπάγεται πως οι ‘’ουρές’’ είναι βαρύτερες από την κανονικής κατανομής, ενώ από την θετική λοξότητα καταλαβαίνουμε πως οι περισσότεροι εργαζόμενοι πληρώνονταν λιγότερο από τον μέσο όρο. Το επάγγελμα με το μεγαλύτερο εισόδημα ήταν των υπεύθυνων αποστολής, με εισόδημα 25879$, ενώ με το μικρότερο ήταν οι αρχιτέκτονες με εισόδημα 611$.

Γ. Γυναίκες

Για τις γυναίκες, βλέπουμε πως κατά μέσο όρο το ποσοστό εμφάνισης τους στον εργασιακό χώρο είναι εμφανώς λιγότερο σε σχέση με των αντρών, κάτι αναμενόμενο, δεδομένου των χρονικών συνθηκών (δεκαετία του 70). Το παραπάνω φαίνεται και από την επικρατούσα τιμή η οποία είναι 0. Όμως, παρατηρούμε μεγάλη διασπορά, πράγμα που σημαίνει ότι ορισμένα επαγγέλματα επικρατούσαν ,σε μεγάλο ποσοστό, οι γυναίκες.

Δ. Κύρος

Σχετικά με το κύρος, η μέθοδος Pineo-Porter δίνει αποτελέσματα από 10 έως 90. Συνεπώς με μέσο κάτω του 50 και θετική λοξότητα ο Καναδάς της δεκαετίας του 70 ήταν κάτω από τον μέσο όρο κύρους με μεγάλη διασπορά. Επίσης, δεδομένου της θετικής κύρτωσης συμπεραίνουμε πως το κύρος στον εργασιακό χώρο ήταν ανομοιόμορφο. Το επάγγελμα με το μεγαλύτερο κύρος ήταν οι bartenders με τιμή μετρημένη στην κλίμακα Pineo-Porter 87.2, ενώ εκείνο με το μικρότερο κύρος ήταν οι ασφαλιστές με τιμή 14.8 στην κλίμακα Pineo-Porter.

Ε. Τύπος επαγγέλματος

Όσον αφορά των τύπο των επαγγελμάτων, παρατηρούμε πως η πλειονότητα αυτών ήταν χειρώνακτες (bc) το οποίο φαίνεται από την επικρατούσα τιμή.

Παρακάτω φαίνεται ο πίνακας ανάλυσης και μελέτης των παραπάνω μεταβλητών μέσω του στατιστικού προγράμματος SPSS.

Statistics

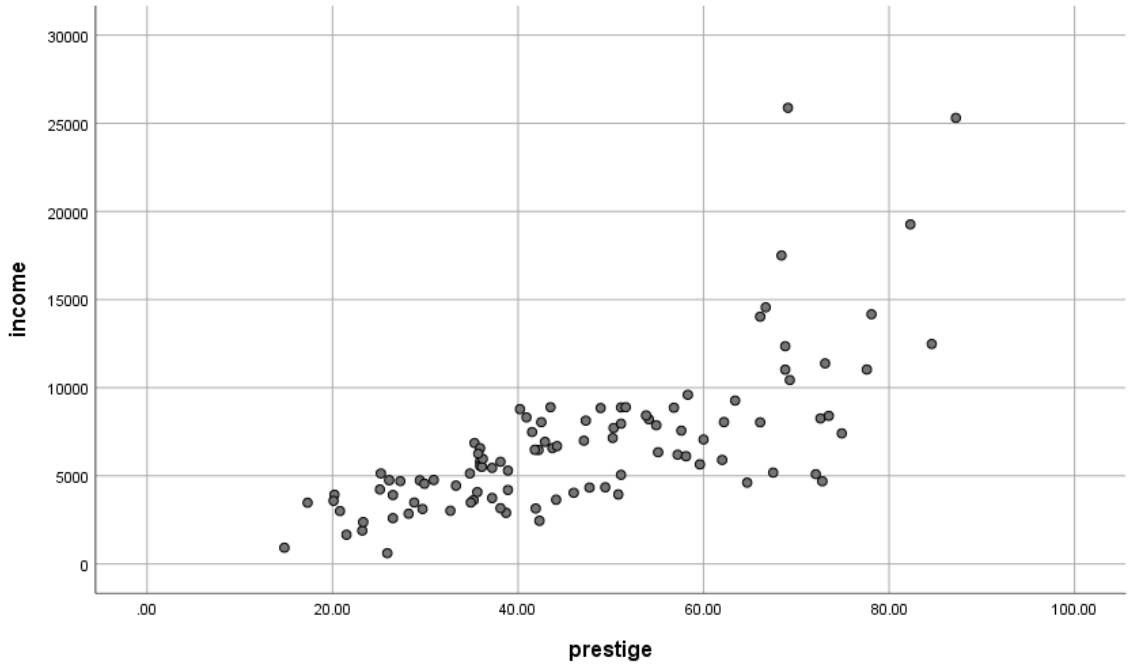
		education	income	women	prestige	type
N	Valid	102	102	102	102	102
	Missing	0	0	0	0	0
Mean		10.7380	6797.90	28.9790	46.8333	
Median		10.5400	5930.50	13.6000	43.6000	2.00
Mode		7.58[a]	3485[a]	.00	35.90[a]	1
Std. Deviation		2.72844	4245.922	31.72493	17.20449	.801
Variance		7.444	18027855.555	1006.471	295.994	.642
Skewness		.335	2.193	.926	.339	.475
Std. Error of Skewness		.239	.239	.239	.239	.239
Kurtosis		-.978	6.863	-.600	-.725	-1.284
Std. Error of Kurtosis		.474	.474	.474	.474	.474
Minimum		6.38	611	.00	14.80	
Maximum		15.97	25879	97.51	87.20	

a. Multiple modes exist. The smallest value is shown

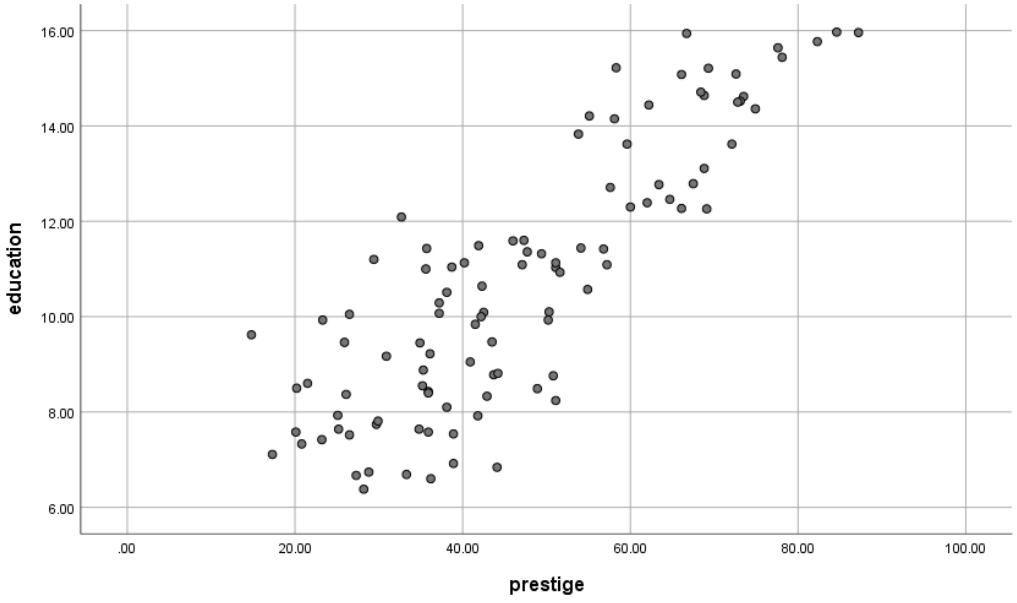
2. Σχέσεις μεταξύ μεταβλητών μέσω απλών γραμμικών μοντέλων

a.) Σημειογράμματα μεταξύ education-prestige και prestige-income.

Παρατηρούμε πως καθώς το κύρος αυξάνεται αυξάνεται και το εισόδημα. Αυτό είναι κάτι αναμενόμενο καθώς τα επαγγέλματα με τους μεγάλους μισθούς έχουν και μεγάλο κύρος.



Κάτι παρόμοιο παρατηρούμε και στο σημειόγραμμα prestige-education. Καθώς αυξάνεται το κύρος ενός επαγγέλματος αυξάνεται και το εισόδημα του. Και αυτό είναι αναμενόμενο αφού ένα επάγγελμα που απαιτεί υψηλό επίπεδο εκπαίδευσης έχει και μεγάλο κύρος.



b.) Εφαρμογή Γραμμικών Μοντέλων

Φτιάχνουμε δύο απλά γραμμικά μοντέλα με εξαρτημένη μεταβλητή την prestige:

$$\mathbf{P_i = \beta_o + \beta_1 I_i + \varepsilon_i} \text{ και } \mathbf{P_i = \beta_2 + \beta_3 E_i + \varepsilon_i'}, \ i = 1,2,\ldots,n$$

όπου $\mathbf{I_i}$,$\mathbf{E_i}$ η i-οστές παρατηρήσεις των επεξηγηματικών μεταβλητών income kai education αντίστοιχα, ενώ $\mathbf{P_i}$ i-οστή παρατήρηση της εξαρτημένης μεταβλητής prestige. Οι συντελεστές παλινδρόμησης είναι οι $\mathbf{\beta_o, \beta_1, \beta_2, \beta_3}$ και ε_i, ε_i' τα αντίστοιχα τυχαία σφάλματα με:

- $\mathbf{E(\varepsilon_i) = 0}$, $\mathbf{E(\varepsilon_i') = 0}$
- $\mathbf{Var(\varepsilon_i) = \sigma^2}$, $\mathbf{Var(\varepsilon_i') = \sigma'^2}$
- Τα $\mathbf{\varepsilon_i}$, $\mathbf{\varepsilon_i'}$ είναι και τα δυο ασυσχέτιστα

c.) Ερμηνεία συντελεστών των ανεξάρτητων μεταβλητών β_1 και β_3

Χρησιμοποιώντας την μέθοδο ελάχιστων τετραγώνων βρίσκουμε εκτιμήτριες των $\mathbf{\beta_1}$ και $\mathbf{\beta_3}$:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{102} (Ii - \bar{I})(Pi - \bar{P})}{\sum_{i=1}^{102} (Ii - I\bar{\circ})2} \text{ και } \hat{\beta}_3 = \frac{\sum_{i=1}^{102} (Ei - \bar{E})(Pi - \bar{P})}{\sum_{i=1}^{102} (Ei - E\bar{\circ})2}$$

,όπου $\bar{I} = \frac{1}{102}\sum_{i=1}^{102} Ii = 6797.9$, $\bar{E} = \frac{1}{102}\sum_{i=1}^{102} Ei = 10.7380$ και $\bar{P} = \frac{1}{102}\sum_{i=1}^{102} Pi = 46.8333$ οι μέσες τιμές μεταβλητών.

Χρησιμοποιώντας το SPSS βρίσκουμε $\hat{\beta}_1 = 0{,}003$ και $\hat{\beta}_3 = 5.361$ όπως φαίνεται και παρακάτω:

Coefficients[a]

Model		Unstandardized Coefficients		Standardized Coefficients		
		B	Std. Error	Beta	t	Sig.
edu	(Constant)	-10.732	3.677		-2.919	.004
	education	5.361	.332	.850	16.148	.000

a. Dependent Variable: prestige

Coefficients[a]

Model		Unstandardized Coefficients		Standardized Coefficients		
		B	Std. Error	Beta	t	Sig.
inc	(Constant)	27.141	2.268		11.969	.000
	income	.003	.000	.715	10.224	.000

a. Dependent Variable: prestige

d.) Έλεγχος στατιστικής σημαντικότητας

Γνωρίζουμε πως οι ανεξάρτητες μεταβλητές είναι χρήσιμες στο να προβλέπουν την εξαρτημένη μεταβλητή όταν το p-value (στο SPSS Sig.) είναι μικρότερο από το επίπεδο σημαντικότητας (0.05)
Και στα δύο μοντέλα έχουμε p-value = 0 <0.05 , συνεπώς και τα δύο μοντέλα είναι στατιστικά χρήσιμα. Αυτό φαίνεται και στους παρακάτω πίνακες του SPSS:

Model		Sig.	95.0% Confidence Interval for B	
			Lower Bound	Upper Bound
inc	(Constant)	.000	22.642	31.640
	income	.000	.002	.003

Model		Sig.	95.0% Confidence Interval for B	
			Lower Bound	Upper Bound
edu	(Constant)	.004	-18.027	-3.437
	education	.000	4.702	6.020

e.) Διαστήματα εμπιστοσύνης

Τα διαστήματα εμπιστοσύνης για τους συντελεστές των δύο μοντέλων σε επίπεδο στατιστικής σημαντικότητας 10% δίνονται στους παρακάτω πίνακες με τη βοήθεια του SPSS:

Model		90.0% Confidence Interval for B	
		Lower Bound	Upper Bound
edu	(Constant)	-16.837	-4.627
	education	4.810	5.912

Model		90.0% Confidence Interval for B	
		Lower Bound	Upper Bound
inc	(Constant)	23.376	30.906
	income	.002	.003

f.) Υπολογισμός R^2 και R^2_{adj} για τα δύο μοντέλα και σχολιασμός

Μέσω του SPSS βρίσκουμε τους τα $\mathbf{R^2}$ και $\mathbf{R^2_{adj}}$ ως εξής:

Model	R	R Square	Adjusted R Square
inc	.715	.511	.506

Model	R	R Square	Adjusted R Square
edu	.850	.723	.720

Γνωρίζουμε πως το $\mathbf{R^2}$ αντιπροσωπεύει το ποσοστό της διακύμανσης για μια εξαρτημένη μεταβλητή που εξηγείται από μια ανεξάρτητη μεταβλητή ή μεταβλητές σε ένα μοντέλο παλινδρόμησης. Άρα αφού για το μοντέλο prestige-income έχουμε $\mathbf{R^2}$ = 0,511 τότε περίπου το ήμισυ της παρατηρούμενης διακύμανσης μπορεί να εξηγηθεί από τις εισόδους του μοντέλου, ενώ αντίστοιχα, για το μοντέλο prestige-education περίπου το 70% της παρατηρούμενης διακύμανσης μπορεί να εξηγηθεί από το μοντέλο. Έτσι καταλαβαίνουμε πως το μοντέλο prestige-education είναι το καλύτερο από τα δύο, όσο αφορά τη διακύμανση.

g.) Χρήση των μοντέλων

Από τα παραπάνω έχουμε ότι:

$$\mathbf{P = 27.141 + 0.003I} \text{ και } \mathbf{P = -10.732 + 5.361E}$$

Για I = 4000$ και E = 10 έτη έχουμε τις προβλέψεις των δύο μοντέλων:

$$\mathbf{P_{inc} = 39.141} \text{ και } \mathbf{P_{edu} = 42.878}$$

Η μέτρηση του prestige είναι προφανώς στην κλίμακα Pineo-Porter.

3. Σχέσεις μεταξύ μεταβλητών μέσω πολλαπλής παλινδρόμησης

a.) Εκτίμηση παραμέτρων για την πολλαπλή παλινδρόμηση και διαστήματα εμπιστοσύνης 95%

Με τη βοήθεια του SPSS, βρίσκουμε τις σταθερές τις πολλαπλής παλινδρόμησης, καθώς και κατασκευάζουμε διαστήματα εμπιστοσύνης 95%. Παρατηρούμε πως τα p-value (sig) είναι μικρότερα από 0.05 για όλες τις παραμέτρους. Έτσι συμπεραίνουμε πως το μοντέλο πολλαπλής παλινδρόμησης είναι στατιστικά σημαντικό και χρήσιμο στην πρόβλεψη του prestige. Όλα αυτά φαίνονται και στον παρακάτω πίνακα:

Model		Unstandardized Coefficients		Sig.	95.0% Confidence Interval for B	
		B	Std. Error		Lower Bound	Upper Bound
1	(Constant)	-6.848	3.219	.036	-13.235	-.461
	income	.001	.000	.000	.001	.002
	education	4.137	.349	.000	3.445	4.830

b.) Υπολογισμός $\mathbf{R^2}$ και $\mathbf{R^2_{adj}}$ για μοντέλο πολλαπλής παλινδρόμησης

Model	R	R Square	Adjusted R Square
1	.893[a]	.798	.794

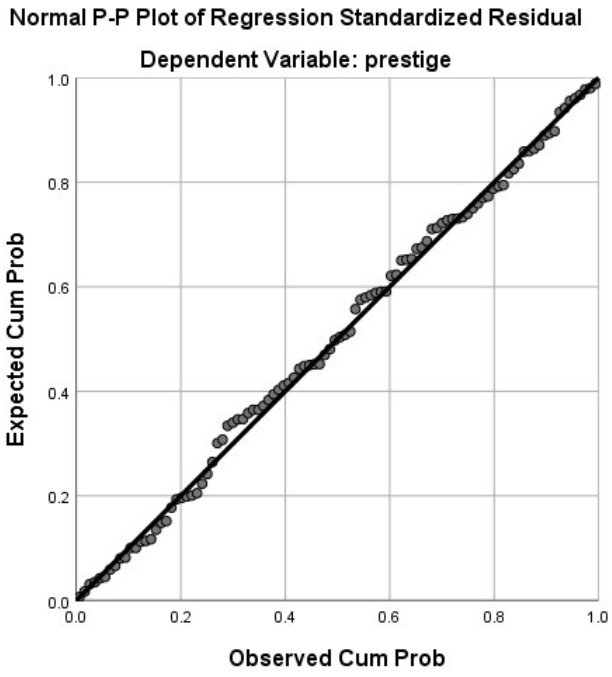
c.) Έλεγχος αρχικών υποθέσεων και Γραφικός Έλεγχος Καταλοίπων

Για να ελέγξουμε τις αρχικές υποθέσεις αρκεί να ελέγξουμε τέσσερεις παράγοντες:

Κανονικότητα, Ομοσκεδαστικότητα, Γραμμικότητα, Απουσία πολυσυγγραμμικότητας.

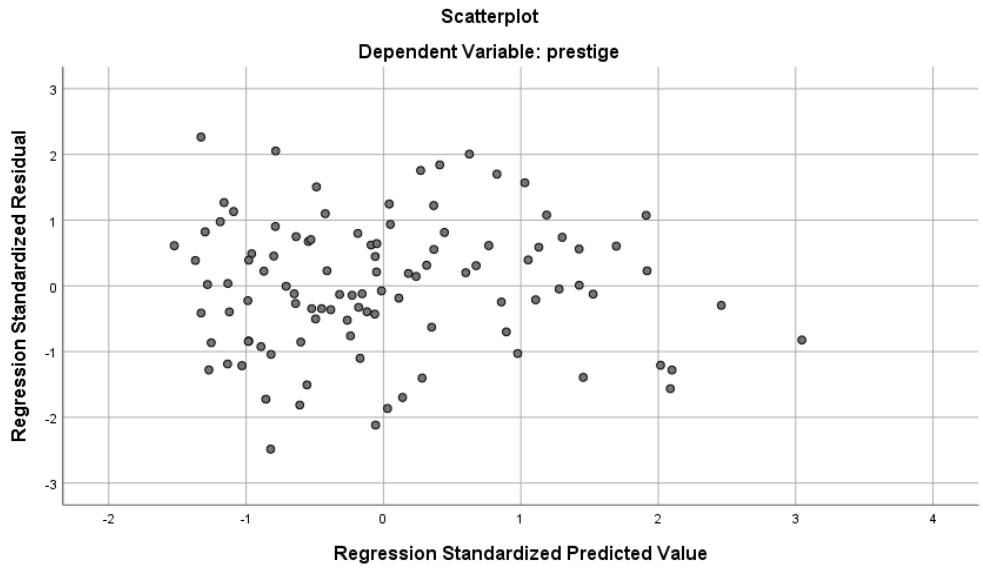
1] Κανονικότητα

Εφαρμόζοντας ένα κανονικό P-P Plot με την βοήθεια του SPSS μπορούμε να ελέγξουμε την κανονικότητα του μοντέλου. Όπως φαίνεται και στο γράφημα παρακάτω, το μοντέλο εφαρμόζει στις αναμενόμενες κανονικές τιμές:



2] Ομοσκεδαστικότητα

Μέσω γραφικού ελέγχου καταλοίπων παρατηρούμε πως το γράφημα, όπως παρουσιάζεται και παρακάτω, δεν έχει εμφανές μοτίβο, υπάρχουν σημεία εξίσου κατανεμημένα πάνω και κάτω από το μηδέν στον άξονα X και αριστερά και δεξιά από το μηδέν στον άξονα Y. Συμπεραίνουμε πώς το μοντέλο δεν μπορεί παρά να είναι ομοσκεδαστικό.



3] Γραμμικότητα

Αφού δείξαμε πως το μοντέλο είναι κανονικό και ομοσκεδαστικό, έπεται η γραμμικότητα του.

4] Απουσία πολυσυγγραμμικότητας

Ελέγχοντας τις τιμές VIF μπορούμε να αποφανθούμε για την παρουσία ή απουσία πολυσυγγραμμικότητας. Πιο συγκεκριμένα, αν οι τιμές VIF είναι μικρότερες του 10, αποτελεί ένδειξη απουσίας πολυσυγγραμμικότητας ενώ για τιμές VIF μικρότερες του 5, η ένδειξη απουσίας καθίσταται ισχυρότερη. Στο μοντέλο μας, οι τιμές VIF βρίσκονται αρκετά χαμηλότερα από το επιθυμητό επίπεδο, το οποίο επιβεβαιώνει και ο πίνακας:

Model		Unstandardized Coefficients		Standardized Coefficients		Collinearity Statistics	
		B	Std. Error	Beta	Sig.	Tolerance	VIF
1	(Constant)	-6.848	3.219		.036		
	income	.001	.000	.336	.000	.666	1.501
	education	4.137	.349	.656	.000	.666	1.501

d.) Σύγκριση του μοντέλου πολλαπλής παλινδρόμησης με τα δύο απλά μοντέλα παλινδρόμησης ως προς R^2 και R^2_{adj}

Όπως περιμένουμε, το πολλαπλό μοντέλο εκτιμά σαφώς καλύτερα την μεταβλητή prestige σε σχέση με τα απλά μοντέλα. Πιο συγκεκριμένα, το ποσοστό της διακύμανσης που εξηγεί η πολλαπλή παλινδρόμηση είναι μεγαλύτερο από οποιοδήποτε από τα δύο απλά μοντέλα. Αυτό είναι προφανές από τα R^2 και R^2_{adj}. Βλέπουμε ότι:

$$\mathbf{0.511 < 0.798 \text{ και } 0.723 < 0.798}$$

$$\mathbf{0.506 < 0.794 \text{ και } 0.720 < 0.794}$$

e.) Χρήση του μοντέλου πολλαπλής παλινδρόμησης και σύγκριση με τα προηγούμενα

Από τα παραπάνω έχουμε ότι:

$$\mathbf{P = -6.848 + 0.001I + 4.137E}$$

Για I = 4000$ και E = 10 έτη παίρνουμε:

$$\mathbf{P = 38.522}$$

Παρατηρούμε πως η πρόβλεψη του πολλαπλού μοντέλου είναι μικρότερη και από τα δύο απλά μοντέλα. Θα εμπιστευόμασταν περισσότερο το πολλαπλό μοντέλο, πρωτίστως επειδή λαμβάνει υπόψη και τις δύο μεταβλητές income και education ταυτόχρονα σε αντίθεση με τα απλά γραμμικά μοντέλα που δεν χαρακτηρίζονται από αντίστοιχη ακρίβεια. Επιπλέον, τα γραμμικά μοντέλα υστερούν του πολλαπλού μοντέλου λόγω των αποτελεσμάτων του ερωτήματος d.)

f.) Έλεγχος στατιστικής σημαντικότητας 5% H_0: $b_{edu} = 4$ vs H_1: $b_{edu} > 4$

Χρησιμοποιούμε την ελεγχοσυνάρτηση:

$$t = \frac{bedu - 4}{\sqrt{V(bedu)}} = \frac{4.137 - 4}{0.349} = 0.392 < \frac{4.830}{2}.$$

Συνεπώς, δεν μπορούμε να απορρίψουμε την αρχική υπόθεση.

4. Μετασχηματισμός μεταβλητής women και ανάλυση διασποράς

a.) Υποθέσεις του μοντέλου ANOVA και εφαρμογή του με ανεξάρτητες κατηγορικές μεταβλητές τις type και women

Υποθέσεις του Μοντέλου ANOVA:

I. Η κατανομή των παρατηρήσεων σε κάθε επίπεδο είναι κανονική.

II. Η κανονική κατανομή για κάθε επίπεδο έχει την ίδια διασπορά.

III. Οι παρατηρήσεις σε κάθε επίπεδο του παράγοντα είναι ανεξάρτητες και ταυτοτικά κατανεμημένες και είναι ανεξάρτητες από τις παρατηρήσεις στα άλλα επίπεδα.

Συνεχίζουμε προσαρμόζοντας ένα μοντέλο ANOVA στο SPSS με σκοπό να διασαφηνίσουμε αν οι ανεξάρτητες μεταβλητές type και women έχουν επίδραση στην διασπορά της income.

Descriptive Statistics

Dependent Variable: income

women	type	Mean	Std. Deviation	N
0	bc	5683.30	2037.010	40
	prof	11659.68	5472.136	25
	wc	6817.50	1432.134	10
	Total	7826.65	4442.110	75
1	bc	2813.50	1082.412	8
	prof	5975.17	1199.125	6
	wc	3694.46	893.587	13
	Total	3940.26	1528.700	27
Total	bc	5205.00	2187.651	48
	prof	10559.45	5422.818	31
	wc	5052.30	1944.325	23
	Total	6797.90	4245.922	102

Στον παραπάνω πίνακα παρατηρούμε πως ενώ οι μισθοί των επαγγελμάτων που επικρατούν οι άντρες, ανεξάρτητα του τύπου του επαγγέλματος, βρίσκονται αρκετά κοντά στον συνολικό μέσο όρο μισθών, οι μισθοί των επαγγελμάτων που υπερισχύουν οι γυναίκες υστερούν σχεδόν κατά το ήμισυ σε σχέση με αυτούς των αντρών ή του μέσου όρου. Από αυτό συμπεραίνουμε πως οι γυναίκες πληρώνονται εμφανώς λιγότερο από τους άντρες. Όσο αναφορά τον τύπο του επαγγέλματος παρατηρούμε πως τα επαγγέλματα τύπου prof (επαγγελματίες, διοικητικοί και τεχνικοί) έχουν σημαντικά μεγαλύτερη τυπική απόκλιση σε σχέση με τα υπόλοιπα, μάλιστα αυξάνοντας τον μέσο όρο, δεδομένου ότι οι μισθοί τους είναι κατά μέσο όρο διπλάσιοι των υπολοίπων.

b.) Έλεγχος της αλληλεπίδρασης και των κύριων επιδράσεων των παραγόντων στην income σε επίπεδο στατιστικής σημαντικότητας 5%

Όπως αναφέραμε και παραπάνω, οι μεταβλητές women και type έχουν εμφανή επίδραση στην απαντητική μεταβλητή. Αυτό μπορούμε να το επιβεβαιώσουμε και μέσω του πίνακα του SPSS παρακάτω. Βλέπουμε πως οι τιμές significance είναι μικρότερες του 0.05 και ίσες με μηδέν και στις δύο μεταβλητές ενδιαφέροντος. Επιπλέον, από τις τιμές του eta squared μπορούμε να αποφανθούμε πως ένα 21% της διασποράς εξηγείται από την μεταβλητή women και άλλο ένα 21% από την μεταβλητή type. Τελικά, παρατηρούμε πως δεν υπάρχει σημαντική αλληλεπίδραση μεταξύ των παραγόντων women και type (sig = 0.271)

Tests of Between-Subjects Effects

Dependent Variable: income

Source	Type III Sum of Squares	df	Mean Square	F	Sig.	Partial Eta Squared
Corrected Model	896891968.616[a]	5	179378393.723	18.638	.000	.493
Intercept	2516453958.162	1	2516453958.162	261.472	.000	.731
women	255553159.669	1	255553159.669	26.553	.000	.217
type	246787515.170	2	123393757.585	12.821	.000	.211

women * type	25494727.668	2	12747363.834	1.325	.271	.027
Error	923921442.404	96	9624181.692			
Total	6534383460.000	102				
Corrected Total	1820813411.020	101				

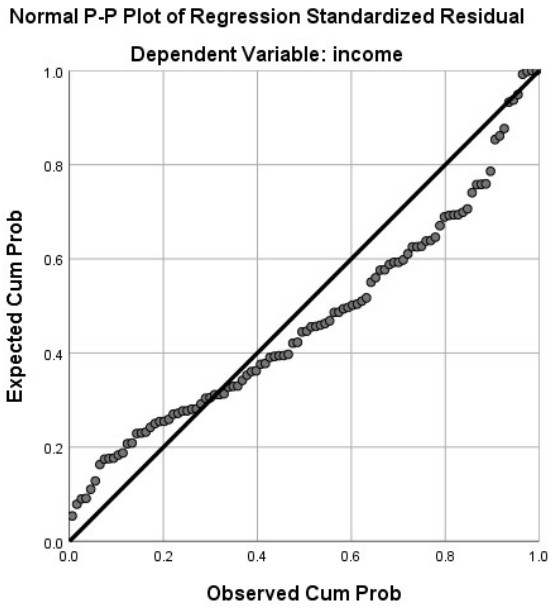
a. R Squared = .493 (Adjusted R Squared = .466)

c.) Έλεγχος των αρχικών υποθέσεων του μοντέλου ANOVA

Αρκεί να ελέγξουμε τις υποθέσεις που αναφέρθηκαν στο ερώτημα **α.)**

I. Κανονικότητα παρατηρήσεων

Η κατανομή των παρατηρήσεων επιβεβαιώνεται πως είναι κανονική όπως φαίνεται στο παρακάτω P-P plot:



Παρατηρούμε πως η κανονικότητα δεν είναι όσο εμφανής όσο σε προηγούμενα μοντέλα, όμως όχι τόσο ώστε να την απορρίψουμε.

II. Ίσες Διασπορές

Η ισότητα των διασπορών μπορεί να μελετηθεί μέσω του τεστ του Bartlett. Πρώτα, με τη βοήθεια του SPSS, βρίσκουμε τον πίνακα συσχέτισης. Παρατηρούμε πως οι μεταβλητές type και women έχουν κάποια σχέση μεταξύ τους. Η αρχική υπόθεση του τεστ του Bartlett είναι πως ο πίνακας συσχέτισης είναι ταυτοτικός, δηλαδή δεν υπάρχει συσχέτιση μεταξύ τους. Απορρίπτουμε την υπόθεση, αφού το significance είναι μικρότερο από 0.05 (sig = 0.001).

Correlation Matrix[a]

		women	type
Correlation	women	1.000	.324
	type	.324	1.000
Sig. (1-tailed)	women		.000
	type	.000	

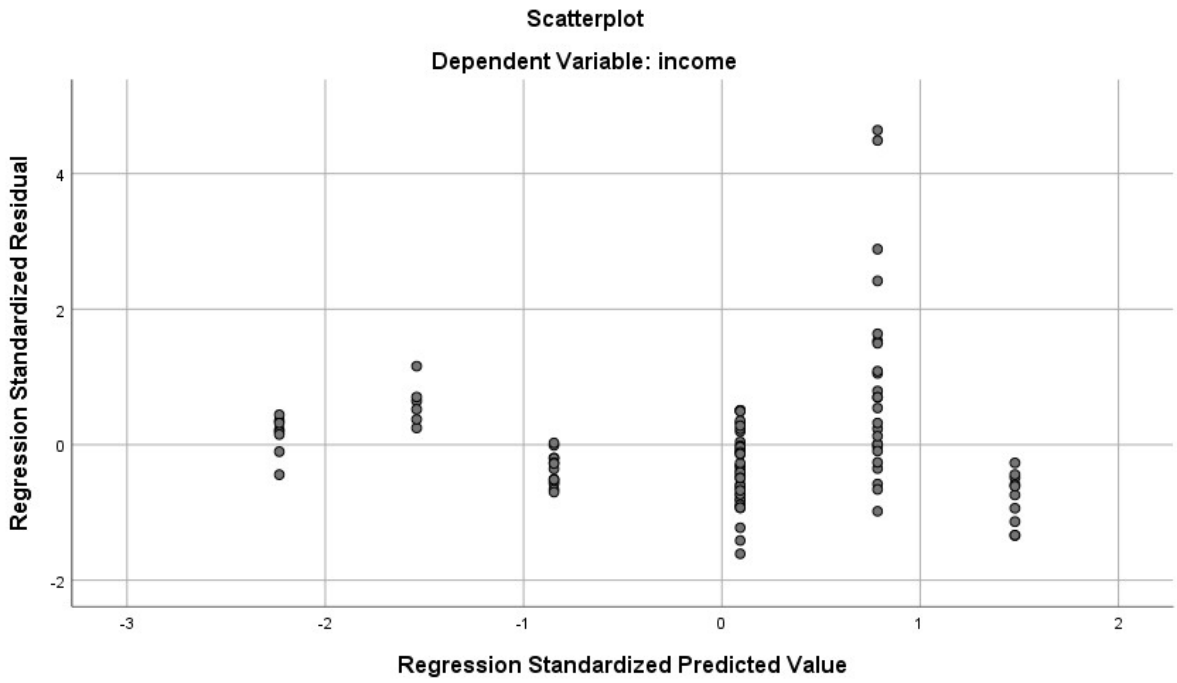
a. Determinant = .895

KMO and Bartlett's Test

Kaiser-Meyer-Olkin Measure of Sampling Adequacy.		.500
Bartlett's Test of Sphericity	Approx. Chi-Square	11.015
	df	1
	Sig.	.001

III. Ομοσκεδαστικότητα, τυχαιότητα, ανεξαρτησία

Όπως θα δούμε και στο παρακάτω scatterplot, οι παρατηρήσεις σε κάθε επίπεδο είναι ανεξάρτητες και ταυτοτικά κατανεμημένες, αλλά και ανεξάρτητες από τις παρατηρήσεις στα άλλα επίπεδα. Το γράφημα διαφέρει αρκετά από το γράγημα καταλοίπων του ερωτήματος 3c. Η διαφορά αυτή οφείλεται στο ότι τώρα έχουμε κατηγορικές μεταβλητές έναντι των συνεχών του προηγούμενου ερωτήματος. Και πάλι όμως, έχουμε ανεξαρτησία παρατηρήσεων για κάθε μεταβλητή.



d.) Επίδραση του κάθε επιπέδου του παράγοντα στην απαντητική μεταβλητή income

Στο ερώτημα b.) βρήκαμε πως και οι δύο μεταβλητές women και type έχουν επίδραση πάνω στην income. Εδώ, θα αποσαφηνίσουμε ποια ακριβώς επίπεδα συμβάλουν στατιστικά σημαντικά στην επίδραση αυτή (Για την μεταβλητή women είναι προφανές αφού έχει δύο επίπεδα).

Pairwise Comparisons

Dependent Variable: income

(I) women	(J) women	Mean Difference (I-J)	Std. Error	Sig.[b]	95% Confidence Interval for Difference[b]	
					Lower Bound	Upper Bound
0	1	3892.451*	755.378	.000	2393.037	5391.864
1	0	-3892.451*	755.378	.000	-5391.864	-2393.037

Based on estimated marginal means

*. The mean difference is significant at the .05 level.

b. Adjustment for multiple comparisons: Least Significant Difference (equivalent to no adjustments).

Pairwise Comparisons

Dependent Variable: income

(I) type	(J) type	Mean Difference (I-J)	Std. Error	Sig.[b]	95% Confidence Interval for Difference[b]	
					Lower Bound	Upper Bound
bc	prof	-4569.023*	926.367	.000	-6407.848	-2730.199
	wc	-1007.581	886.900	.259	-2768.064	752.902
prof	bc	4569.023*	926.367	.000	2730.199	6407.848
	wc	3561.443*	960.695	.000	1654.479	5468.407
wc	bc	1007.581	886.900	.259	-752.902	2768.064
	prof	-3561.443*	960.695	.000	-5468.407	-1654.479

Based on estimated marginal means

*. The mean difference is significant at the .05 level.

b. Adjustment for multiple comparisons: Least Significant Difference (equivalent to no adjustments).

Είναι εμφανές, πως τα επαγγέλματα τύπου prof ευθύνονται για την επίδραση της μεταβλητής type στην income σε επίπεδο στατιστικής σημαντικότητας 5%. Το αποτελέσματα αυτά φαίνονται καθαρά και στο παρακάτω διάγραμμα:

